

# Redes Neurais Artificiais

## Exemplo de Aprendizado Supervisionado com o Neurônio Perceptron

**Elloá B. Guedes**

Escola Superior de Tecnologia  
Universidade do Estado do Amazonas  
Av. Darcy Vargas, 1200 – Manaus, AM  
ebgcosta@uea.edu.br

30 de agosto de 2020

### 1. Apresentação

Este documento é inspirado na Seção 2.3.5 do trabalho de Braga et al. [1] com o intuito de detalhar os passos do Aprendizado Supervisionado de um neurônio Perceptron perante um conjunto de dados de treinamento. Foram adicionadas figuras de autoria própria e outras observações advindas de fontes referenciadas ao longo do documento.

### 2. Conjunto de Treinamento

Considerando que neste exemplo o aprendizado ocorre de maneira supervisionada, o conjunto de treinamento  $\Gamma$  possui pares na forma  $(\mathbf{x}, y)$ , em que  $\mathbf{x}$  é o vetor de entrada dos atributos e  $y$  é a saída para esta entrada, obtida junto a um especialista no problema. Assim, tem-se um conjunto de treinamento com dois pares de exemplos e nomenclatura adotada destacada na cor azul:

$$\Gamma = \left\{ \left( \underbrace{\begin{bmatrix} 2 & 2 \end{bmatrix}}_{x(1)}, \underbrace{1}_{y_d^1} \right), \left( \underbrace{\begin{bmatrix} 4 & 4 \end{bmatrix}}_{x(2)}, \underbrace{0}_{y_d^2} \right) \right\} \quad (1)$$

Observe que o problema em questão é linearmente separável a partir da representação dos exemplos disponíveis no plano cartesiano, conforme denotado na Figura 1. Consideram-se os atributos como  $x_1$  e  $x_2$  e as classes como sendo denotadas em cores e formas distintas.




Figura 1: Ilustração dos exemplos do conjunto de treinamento no plano cartesiano. A classe 1 é representada por um quadrado vermelho e a classe 0 é representada por um círculo azul.

### 3. Parâmetros e Hiperparâmetros

Para resolver este problema, será utilizado o modelo de neurônio artificial *Perceptron de Rosenblatt* [2], o qual adiciona um viés à entrada em contraste ao modelo de neurônio artificial de Mcculloch & Pitts [3]. Considerado o problema em questão, tem-se a seguinte instância ilustrada na Figura 2.




Figura 2: Neurônio perceptron de Rosenblatt instanciado para o problema.

Assume-se que o vetor de pesos inicial  $w(0)$  foi inicializado de maneira aleatória, com os seguintes valores:

$$w(0) = \begin{bmatrix} -0,5441 \\ 0,5562 \\ -0,4074 \end{bmatrix} \quad (2)$$

Outro parâmetro que precisa ser definido neste neurônio é a função de ativação. Neste caso será utilizada a função de ativação degrau com limiar  $\vartheta = 0$ , dada na Eq. (3) e ilustrada graficamente na Figura 3.

$$f(u) = \begin{cases} 1, & u \geq \vartheta = 0 \\ 0, & \text{c.c.} \end{cases} \quad (3)$$




Figura 3: Função de ativação degrau.

Neste problema, o único hiperparâmetro a ser definido é a taxa de aprendizado  $\eta$ , a qual determina a taxa em que os pesos serão ajustados. Um valor muito pequeno de  $\eta$  pode implicar em demora para convergência, ao passo que um valor muito grande pode gerar instabilidade no treinamento. Em termos práticos, para este tipo de problema, recomenda-se que o valor desta taxa esteja no intervalo  $0,1 \leq \eta \leq 0,4$ . Neste exemplo, será adotado o valor  $\eta = 0,1$ .

## 4. Necessidade de Aprendizado

Para justificar a necessidade de ajustes nos pesos do neurônio em questão, basta verificar que tais valores não permitem uma distinção clara entre os exemplos das classes existentes.

Para o exemplo  $x(1)$ , tem-se:

$$u = \sum_{i=0}^2 x_i w_i \quad (4)$$

$$= -1 \cdot (-0,5441) + 2 \cdot 0,5562 + 2 \cdot (-0,4074) \quad (5)$$

$$= 0,5441 + 1,1124 - 0,8148 \quad (6)$$

$$= 0,8417. \quad (7)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(u) \quad (8)$$

$$= f(0,8417) \quad (9)$$

$$= 1. \quad (10)$$

Como  $y = y_d^1$ , tem-se que o neurônio em questão prevê corretamente esta entrada.

De maneira análoga, tem-se o que segue para o exemplo  $x(2)$ :

$$u = \sum_{i=0}^2 x_i w_i \quad (11)$$

$$= -1 \cdot (-0,5441) + 4 \cdot 0,5562 + 4 \cdot (-0,4074) \quad (12)$$

$$= 0,5441 + 2,2248 - 1,6296 \quad (13)$$

$$= 1,1459. \quad (14)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(u) \quad (15)$$

$$= f(1,1459) \quad (16)$$

$$= 1. \quad (17)$$

Como  $y \neq y_d^2$ , tem-se que o neurônio em questão não prevê corretamente a saída esperada esta entrada.

O aprendizado em neurônios Perceptron dá-se pelo ajuste de pesos, conforme estabelecido pela Regra Delta:

$$w(n+1) = w(n) + \Delta w(n) \quad (18)$$

$$= w(n) + \eta \cdot e \cdot x(n), \quad (19)$$

, em que  $\eta$  é a taxa de aprendizado,  $e$  denota o erro, dado pela diferença entre os valores previstos e desejados, isto é,  $e = (y_d - y)$ , e  $x(n)$  corresponde à entrada para a qual a respectiva previsão deu-se de maneira incorreta, ajudando a determinar a direção correta do ajuste do vetor de pesos. De maneira geométrica, a Regra Delta pode ser interpretada como mostrado na Figura 4.




Figura 4: Interpretação geométrica da Regra Delta.

Visto que o neurônio em questão é incapaz de prever corretamente a saída para a entrada  $x(2)$ , segue-se então o processo de Aprendizado Supervisionado.

## 5. Ilustração do Processo de Aprendizado

O algoritmo de treinamento do Perceptron é composto pelos seguintes passos:

1. Inicialize  $\eta$ ;
2. Inicialize o vetor de pesos  $w(0)$  com valores aleatórios;
3. Aplique a regra de atualização dos pesos:

$$w(n+1) = w(n) + \eta \cdot e \cdot x(n)$$

para todos os  $p$  pares  $(x(i), y_d^i)$  do conjunto de treinamento  $\Gamma$ ;

4. Repita o passo anterior até que  $e = 0$  para todos os  $p$  elementos de  $\Gamma$ .

Denomina-se e enumera-se em épocas a cada vez que o Passo 3 é aplicado, sem que a condição de parada estabelecida pelo Passo 4 seja alcançada. Assim, o processo de aprendizado deste neurônio será organizado sob a forma de épocas.

### 5.1 Primeira Época

Usando o par  $(x(1), y_d^1)$ :

$$u = \sum_{i=0}^2 x_i w_i \quad (20)$$

$$= -1 \cdot (-0,5441) + 2 \cdot 0,5562 + 2 \cdot (-0,4074) \quad (21)$$

$$= 0,5441 + 1,1124 - 0,8148 \quad (22)$$

$$= 0,8417. \quad (23)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(u) \quad (24)$$

$$= f(0,8417) \quad (25)$$

$$= 1. \quad (26)$$

Observa-se que o valor  $y$  previsto pelo neurônio é igual ao valor de  $y_d^1$ . Em consequência,  $e = (y_d^1 - y) = (1 - 1)$  e, portanto, não há necessidade de ajuste, o que é verificado quando aplica-se a Regra Delta:

$$w(1) = w(0) + \eta \cdot e \cdot x(1) = \begin{bmatrix} -0,5441 \\ 0,5562 \\ -0,4074 \end{bmatrix} + 0,1 \cdot (1 - 1) \cdot \begin{bmatrix} -1 \\ 2 \\ 2 \end{bmatrix} \quad (27)$$

$$= \begin{bmatrix} -0,5441 \\ 0,5562 \\ -0,4074 \end{bmatrix} \quad (28)$$

De modo análogo, com o próximo exemplo  $(x(2), y_d^2)$  disponível na base de dados:

$$u = \sum_{i=0}^2 x_i w_i \quad (29)$$

$$= -1 \cdot (-0,5441) + 4 \cdot 0,5562 + 4 \cdot (-0,4074) \quad (30)$$

$$= 0,5441 + 2,2248 - 1,6296 \quad (31)$$

$$= 1,1459. \quad (32)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(u) \quad (33)$$

$$= f(1,1459) \quad (34)$$

$$= 1. \quad (35)$$

Note que houve erro, pois  $y \neq y_d^2$ . Assim, há necessidade de ajuste no vetor de pesos, o qual é dado por:

$$w(2) = w(1) + \eta \cdot e \cdot x(2) = \begin{bmatrix} -0,5441 \\ 0,5562 \\ -0,4071 \end{bmatrix} + 0,1 \cdot (0 - 1) \cdot \begin{bmatrix} -1 \\ 4 \\ 4 \end{bmatrix} \quad (36)$$

$$= \begin{bmatrix} -0,5441 \\ 0,5562 \\ -0,4071 \end{bmatrix} + \begin{bmatrix} +0,1 \\ -0,4 \\ -0,4 \end{bmatrix} = \begin{bmatrix} -0,4441 \\ 0,1562 \\ -0,8074 \end{bmatrix} \quad (37)$$

Todos os exemplos de  $\Gamma$  foram apresentados ao neurônio. Conclui-se, portanto, a primeira época.

## 5.2 Segunda Época

Dando prosseguimento ao treinamento, usando o par  $(x(1), y_d^1)$  e os pesos de  $w(2)$ :

$$u = \sum_{i=0}^2 x_i w_i \quad (38)$$

$$= -1 \cdot (-0,4441) + 2 \cdot 0,1562 + 2 \cdot (-0,8074) \quad (39)$$

$$= 0,4441 + 0,3124 - 1,6148 \quad (40)$$

$$= -0,8614. \quad (41)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(-0,8614) = 0. \quad (42)$$

Como  $y \neq y_d^1$ , tem-se o ajuste de pesos:

$$w(3) = w(2) + \eta \cdot e \cdot x(1) = \begin{bmatrix} -0,4441 \\ 0,1562 \\ -0,8074 \end{bmatrix} + 0,1 \cdot (1 - 0) \cdot \begin{bmatrix} -1 \\ 2 \\ 2 \end{bmatrix} \quad (43)$$

$$= \begin{bmatrix} -0,4441 \\ 0,1562 \\ -0,8074 \end{bmatrix} + \begin{bmatrix} -0,1 \\ 0,2 \\ 0,2 \end{bmatrix} = \begin{bmatrix} -0,5441 \\ 0,3562 \\ -0,6074 \end{bmatrix} \quad (44)$$

Agora usando o exemplo  $(x(2), y_d^2)$ :

$$u = \sum_{i=0}^2 x_i w_i \quad (45)$$

$$= -1 \cdot (-0,5441) + 4 \cdot 0,3562 + 4 \cdot (-0,6074) \quad (46)$$

$$= 0,5441 + 1,4248 - 2,4296 \quad (47)$$

$$= -0,4607. \quad (48)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(-0,4607) = 0. \quad (49)$$

Não houve erro, uma vez que  $y = y_d^2$ . Isto será refletido no vetor de pesos  $w(4)$ , o qual não sofrerá atualizações quando comparado ao vetor de pesos  $w(3)$ :

$$w(4) = w(3) + \eta \cdot e \cdot x(2) \quad (50)$$

$$= \begin{bmatrix} -0,4441 \\ 0,3562 \\ -0,6074 \end{bmatrix} + 0,1 \cdot (0 - 0) \cdot \begin{bmatrix} -1 \\ 4 \\ 4 \end{bmatrix} \quad (51)$$

$$= \begin{bmatrix} -0,5441 \\ 0,3562 \\ -0,6074 \end{bmatrix} \quad (52)$$

Todos os exemplos de  $\Gamma$  foram apresentados ao neurônio. Conclui-se, portanto, a segunda época.

### 5.3 Terceira Época

Usando o par  $(x(1), y_d^1)$  e os pesos de  $w(4)$ :

$$u = \sum_{i=0}^2 x_i w_i \quad (53)$$

$$= -1 \cdot (-0,5441) + 2 \cdot 0,3562 + 2 \cdot (-0,6074) \quad (54)$$

$$= 0,5441 + 0,7124 - 1,2148 \quad (55)$$

$$= 0,0417. \quad (56)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(0,0417) = 1. \quad (57)$$

Note que não houve erro. Assim:

$$w(5) = w(4) + \eta \cdot e \cdot x(1) \quad (58)$$

$$= \begin{bmatrix} -0,5441 \\ 0,3562 \\ -0,6074 \end{bmatrix} + 0,1 \cdot (1 - 1) \cdot \begin{bmatrix} -1 \\ 2 \\ 2 \end{bmatrix} \quad (59)$$

$$= \begin{bmatrix} -0,5441 \\ 0,3562 \\ -0,6074 \end{bmatrix}. \quad (60)$$

Seguindo para o próximo exemplo  $(x(2), y_d^2)$ , tem-se:



$$u = \sum_{i=0}^2 x_i w_i \quad (61)$$

$$= -1 \cdot (-0,5441) + 4 \cdot 0,3562 + 4 \cdot (-0,6074) \quad (62)$$

$$= 0,5441 + 1,4248 - 2,4296 \quad (63)$$

$$= -0,4607 \quad (64)$$

$$(65)$$

Aplicando-se a função de ativação, tem-se:

$$y = f(-0,4607) = 0. \quad (66)$$

Note que também não houve erro. Assim, tem-se:

$$w(6) = w(5) + \eta \cdot e \cdot x(2) \quad (67)$$

$$= \begin{bmatrix} -0,5441 \\ 0,3562 \\ -0,6074 \end{bmatrix} + 0,1 \cdot (0 - 0) \cdot \begin{bmatrix} -1 \\ 4 \\ 4 \end{bmatrix} \quad (68)$$

$$= \begin{bmatrix} -0,5441 \\ 0,3562 \\ -0,6074 \end{bmatrix}. \quad (69)$$

Observe que  $w(4) = w(5) = w(6)$  e, em consequência, o Passo 4 do algoritmo de treinamento do neurônio perceptron foi satisfeito. Encerra-se então o treinamento tendo o vetor de pesos  $w(5)$  como solução para o problema proposto.

## 6. Interpretação do Resultado

Ao final do treinamento, identificou-se o vetor  $w(6)$  como sendo capaz de prover a saída correta para todos os exemplos em  $\Gamma$ . Na Figura 1 foi possível obter a visualização de que o problema era linearmente separável, mas qual a relação dos pesos obtidos com a reta que separa as classes do problema?

A resposta para esta pergunta é obtida por meio de uma reta que separa as classes do problema advinda dos pesos do neurônio, a qual é expressa da seguinte forma:

$$x_2 = (w_0/w_2) - (w_1/w_2)x_1. \quad (70)$$

No exemplo em questão, tem-se:




Figura 5: Resolução do problema linearmente separável proposto.

$$x_2 = \left( \frac{-0,5441}{-0,6074} \right) - \left( \frac{0,3562}{-0,6074} \right) \cdot x_1 \quad (71)$$

$$= 0,8957 + 0,5864 \cdot x_1. \quad (72)$$

Ao traçar esta reta, denotada na Figura 5 na cor roxa, vê-se claramente as regiões de ativação e não-ativação do neurônio para o problema.

## Referências

- [1] DE PÁDUA BRAGA, A.; DE LEON F. DE CARVALHO, A. P.; LUDERMIR, T. B. *Redes neurais artificiais: Teoria e aplicações*. 2. ed. Rio de Janeiro, Brasil: LTC, 2012.
- [2] ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, Washington, v. 6, n. 65, p. 386–408, 1958.
- [3] MCCULLOCH, W.; PITTS, W. A logical calculus of ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, v. 5, p. 127–147, 1943.